

INFERÊNCIA ESTATÍSTICA (EST0035)

AULA02: DISTRIBUIÇÕES AMOSTRAIS

Frederico Machado Almeida
frederico.almeida@unb.br

Departamento de Estatística
Instituto de Exatas
Universidade de Brasília (UnB)

Distribuições Amostrais

- Vimos anteriormente que, uma estatística (ou estimador) $T_n = T(X_1, \dots, X_n)$ é qualquer função de uma a.a., e portanto, também é uma v.a.
- Consequentemente, T_n pode estar associada a uma distribuição de probabilidades (distribuição amostral da estatística).

Exemplo 6: um jogo consiste em lançar uma moeda honesta 3 vezes. Para cada lançamento, se sair cara o jogador ganha 1 ponto, caso saia coroa, ele perde 1 ponto. Nisso, podemos modelar essa situação através de uma v.a.

$$X_i = \begin{cases} +1 & \text{com } p = 1/2, \\ -1 & \text{com } q = 1/2. \end{cases}$$

Como o experimento consiste em lançar uma a moeda honesta 3 vezes, vamos denotar por (X_1, X_2, X_3) , a nossa a.a.

Distribuições Amostrais

Objetivo: encontrar as distribuições de probabilidades para os estimadores $T_{1n} = \bar{X}_n$ e $T_{2n} = S^2$, que denotam a média e variância amostral, respectivamente.

- Fazendo os devidos cálculos, obtemos os seguintes resultados:

\bar{x}_n	-1	-1/3	1/3	1
$P(\bar{X}_n = \bar{x}_n)$	1/8	3/8	3/8	1/8

Tabela: Distribuição amostral da média $T_{1n} = \bar{X}_n$.

s_n^2	0	4/3
$P(S^2 = s_n^2)$	1/4	3/4

Tabela: Distribuição amostral da variância $T_{2n} = S^2$.

- Por fim, podemos provar que T_{1n} e T_{2n} são estimadores não-viesados para μ e σ^2 , respectivamente.

Distribuições Amostrais

- Observe que, no exemplo anterior, foi possível enumerar todas as amostras necessárias, e de seguida conseguimos obter as distribuições de probabilidades de T_{1n} e T_{2n} .
- No entanto, na maioria das vezes não é viável enumerar todos resultados possíveis. Portanto, precisamos de ferramentas que possam nos auxiliar a encontrar as distribuições dos estimadores, nos casos em que não conseguimos enumerar todas as possíveis a.a.'s.
- Obter a distribuição amostral de uma estatística T_n é um processo tão (mais) complexo do que trabalhar com toda a população (caso seja possível).

Distribuição Amostral de \bar{X}_n

- Nas aulas anteriores vimos que a média amostral \bar{X} é um estimador não-viesado para a quantidade alvo θ . No entanto, o teorema abaixo estabelece um resultado importante.

Teorema 1

Seja X_1, \dots, X_n uma a.a. de tamanho n extraída de uma população representada pela v.a. X . Tal que, $\mu = \mathbb{E}(X)$ e $\sigma^2 = \text{Var}(X)$. Então, segue que,

- $\mathbb{E}_\mu(\bar{X}_n) = \mu,$
- $\text{Var}_{\sigma^2}(\bar{X}_n) = \sigma^2/n.$

Prova: A parte (i) da prova já foi apresentada anteriormente. A prova da parte (ii) é trivial, e será apresentada na sala de aula!!!

Distribuição Amostral de \bar{X}_n

- É importante esclarecer que o resultado do Teorema 1 vale para qualquer população associada a v.a. X .
- Numa primeira fase, vamos considerar o caso em que a a.a. é proveniente de uma população normal com média $\mu \in \mathbb{R}$ e variância $\sigma^2 > 0$, sendo os parâmetros de localização e escala, respetivamente. O teorema a seguir estabelece uma distribuição amostrar para \bar{X} .

Teorema 2

Seja X_1, \dots, X_n uma a.a. de tamanho n proveniente de uma população normal, isto é, $X \sim \mathcal{N}(\mu, \sigma^2)$. Então, segue imediatamente que $\bar{X}_n \sim \mathcal{N}(\mu, \sigma^2/n)$.

Distribuição Amostral de \bar{X}_n




Figura: Distribuição amostral da média $T_n = \bar{X}_n$, para a.a.'s extraídas de uma população $X \sim \mathcal{N}(2, 1)$.

Distribuição Amostral de \bar{X}_n

- Os histogramas apresentados na figura anterior, mostram claramente que a variância de \bar{X}_n decresce com o aumento do tamanho de amostra (consequência do fato de que a variância de \bar{X}_n depende do tamanho de amostra).
- Assim, fica evidente que a variância da v.a. X será sempre maior do que a variância de \bar{X}_n , $\forall n > 1$.
- Encontrada a distribuição de probabilidades de $T_n = \bar{X}_n$, podemos calcular probabilidades do estimador ser maior, menor, ou estar compreendido em um determinado intervalo.

Distribuição Amostral de \bar{X}_n

Exemplo 7: A capacidade máxima de um elevador é de 500kg. Se a distribuição dos pesos dos usuários segue o modelo normal com média $\mu = 70kg$ e variância $\sigma^2 = 100kg^2$, qual é a probabilidade de que 7 pessoas ultrapassem esse limite? E de 6 Pessoas?

Distribuição Amostral de \bar{X}_n

- Observe que, a normalidade da distribuição amostral de \bar{X}_n apresentada anteriormente, é exata, no sentido de que \bar{X}_n resulta de uma combinação linear de v.a.'s normais.
- No entanto, na teoria estatística, é comum nos depararmos com a v.a. X segue uma distribuição qualquer (podendo ser próxima ou distante da normal). Assim, como podemos proceder para encontrar a distribuição amostral de \bar{X}_n ?
- A resposta para essa pergunta está associada ao famoso Teorema Central do Limite (TCL)

Distribuição Amostral de \bar{X}_n

Teorema 3 (TCL)

Seja X_1, \dots, X_n uma a.a. proveniente de uma população F , caracterizada pela média $\mu < \infty$ e variância $\sigma^2 > 0$. Então, a distribuição da média amostral \bar{X}_n converge para uma distribuição normal de média μ e variância σ^2/n , i.e., $\bar{X}_n \stackrel{a}{\sim} \mathcal{N}(\mu, \sigma^2/n)$.

- Como consequência do TCL, segue imediatamente que,

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \stackrel{a}{\sim} \mathcal{N}(0, 1). \quad (1)$$

Prova: Uma das formas de provar a veracidade do TCL, seria por meio da função geradora de momentos (fgm), ou função característica. Porém, os detalhes não serão apresentados aqui.

Distribuição Amostral de \bar{X}_n




Figura: Aproximação da distribuição exponencial para normal, para $T_n = \bar{X}_n$.

Distribuição Amostral de \bar{X}_n




Figura: Aproximação da distribuição Poisson para normal, para $T_n = \bar{X}_n$.

Distribuição Amostral de S^2

- Diferentemente do que foi apresentado sobre a distribuição da média amostral \bar{X}_n , a obtenção da distribuição da variância amostral S^2 requer que a a.a. seja proveniente de uma população normal.
- Como é de conhecimento, existem dois estimadores para a variância populacional, $\hat{\sigma}_n^2$ e S^2 , sendo que, o primeiro é um estimador viesado para σ^2 .

Teorema 4

Seja X_1, \dots, X_n uma a.a. extraída de uma população normal com média $\mu \in \mathbb{R}$ e variância $\sigma^2 > 0$. Assim, a distribuição da variância amostral S^2 é Qui-Quadrado com $n - 1$ graus de liberdade.

Distribuição Amostral de S^2

Prova: para provar o teorema 4, defina $U = (n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$. De seguida, vamos decompor a quantidade,

$$\underbrace{\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2}_{\sim \chi_n^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}_n}{\sigma} \right)^2 + \underbrace{\left(\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \right)^2}_{\sim \chi_1^2}.$$

Consequentemente, $U = (n-1)S^2/\sigma^2 = \sum_{i=1}^n Z_i^2 - Z_n^2 \sim \chi_{n-1}^2$. O resultado anterior é facilmente obtido usando a *fgm*.

Distribuição Amostral de S^2

- Portanto, em decorrência do resultado anterior, podemos concluir que, a fdp da v.a. U é dada por,

$$f(u|n) = \frac{1}{2^{\frac{n-1}{2}} \Gamma\left(\frac{n-1}{2}\right)} u^{\frac{n-1}{2}-1} \exp\left(-\frac{u}{2}\right). \quad (2)$$

- Nisso, segue imediatamente que, $\mathbb{E}(U) = n-1$ e $\text{Var}(U) = 2(n-1)$. Ademais, podemos escrever S^2 como, $S^2 = \frac{U\sigma^2}{(n-1)}$. Assim,

$$(i) \quad \mathbb{E}(S^2) = \mathbb{E}\left\{\frac{U\sigma^2}{(n-1)}\right\} = \frac{\sigma^2}{(n-1)} \mathbb{E}(U) = \sigma^2$$

$$(ii) \quad \text{Var}(S^2) = \text{Var}\left\{\frac{U\sigma^2}{(n-1)}\right\} = \frac{\sigma^4}{(n-1)^2} \text{Var}(U) = \frac{2\sigma^4}{(n-1)}$$

Distribuição Amostral de S^2

Algumas Características da Distribuição χ_{n-1}^2

- A distribuição χ_{n-1}^2 é um caso particular da distribuição $\Gamma\left(\frac{n-1}{2}, \frac{1}{2}\right)$.
- É uma distribuição assimétrica positiva.
- Seu aspecto visual depende do tamanho de amostra, que é o parâmetro caracterizador da distribuição.
- É uma distribuição aditiva, no sentido de que, se as v.a.'s são iids $Y_i \sim \chi_{n_i}^2$ então, $\sum_{i=1}^n Y_i \sim \chi_m^2$, com $m = \sum_{i=1}^n n_i$.
- Se $Z \sim \mathcal{N}(0, 1)$, segue imediatamente que, $Z^2 \sim \chi_1^2$.
- A distribuição χ_{n-1}^2 se aproxima da distribuição normal que n cresce. Esse é um resultado direto do TCL. Isto é,

$$\frac{Y - (n-1)}{\sqrt{2(n-1)}} \stackrel{a}{\sim} \mathcal{N}(0, 1).$$

Distribuição Amostral da Proporção \hat{p}_n

- O TCL anunciado anteriormente afirma que, se X é uma v.a. proveniente de uma população qualquer F , tal que, $\mu = \mathbb{E}(X)$ e $\sigma^2 = \text{Var}(X)$, então, a média amostral \bar{X}_n segue uma distribuição normal com média μ e variância σ^2/n .

Teorema 5

Seja X_1, \dots, X_n uma a.a. proveniente de uma população com fda F . Se $\mu = \mathbb{E}(X)$ e $\sigma^2 = \text{Var}(X)$ denotam a média e a variância de X , então, para a estatística $S_n = \sum_{i=1}^n X_i = n\bar{X}_n$, podemos estabelecer o seguinte resultado:

- i $\mathbb{E}(S_n) = n\mu,$
- ii $\text{Var}(S_n) = n\sigma^2.$

Distribuição Amostral da Proporção \hat{p}_n

- Supondo que X_i assume apenas dois resultados possíveis, isto é,

$$X_i = \begin{cases} 1 & \text{com probabilidade } p \\ 0 & \text{com probabilidade } q \end{cases}$$

então, a estatística S_n denota a contagem do número de sucessos em n repetições independentes do experimento. Assim, $\mathbb{E}(X_i) = p$ e $\text{Var}(X_i) = p(1 - p)$, segue imediatamente que,

- $\mathbb{E}(S_n) = np$,
- $\text{Var}(S_n) = np(1 - p)$.

- Portanto, segue do TCL que, $S_n \sim \mathcal{N}(np, np(1 - p))$ quando $n \rightarrow \infty$. Consequentemente,

$$\frac{S_n - \mathbb{E}(S_n)}{\sqrt{\text{Var}(S_n)}} = \frac{S_n - np}{\sqrt{np(1 - p)}} \stackrel{a}{\sim} \mathcal{N}(0, 1).$$

Distribuição Amostral da Proporção \hat{p}_n

Atenção: a aproximação da distribuição binomial para a normal será considerada válida quando as seguintes condições forem satisfeitas:

- i $np \geq 5$
 - ii $n(1 - p) \geq 5$.
- Usando o resultado da aproximação binomial à normal, e usando o fato de que $\hat{p}_n = S_n/n$, segue imediatamente que,
 $\hat{p}_n \sim \mathcal{N}(p, p(1 - p)/n)$, quando $n \rightarrow \infty$.
 - Alternativamente, temos que:

$$\frac{S_n/n - \mathbb{E}(S_n/n)}{\sqrt{\text{Var}(S_n/n)}} = \frac{\hat{p}_n - p}{\sqrt{p(1 - p)/n}} \stackrel{a}{\sim} \mathcal{N}(0, 1).$$

Com $\mathbb{E}(\hat{p}_n) = p$ e $\text{Var}(\hat{p}_n) = p(1 - p)/n$.

Distribuição Amostral da Proporção \hat{p}_n




Figura: Distribuição amostral da proporção $T_n = \hat{p}_n$. Paine1-1 ($p = 0,025$), Paine1-2 ($p = 0,25$), Paine1-3 ($p = 0,50$), Paine1-4 ($p = 0,75$).

Distribuição Amostral da Proporção \hat{p}_n

Exemplo 8: De um grande lote de produtos manufaturados, extrai-se uma a.a. simples de 200 itens. Se 10% dos itens são defeituosos, qual é a probabilidade de serem sorteados no máximo, 24 itens defeituosos?

Exemplo 9: A confiabilidade de um componente é a probabilidade de que ele funcione sob as condições desejadas. Uma amostra a.a. simples de 2500 desses componentes é extraída, e cada componente testado. Pede-se para calcular a probabilidade de se obter pelo menos 75 itens defeituosos, supondo que a confiabilidade seja de:

- a) 0,995
- b) 0,850.

Distribuição F de Snedecor

- Outra distribuição que tem sido frequentemente considerada na literatura, é a distribuição F de Snedecor.
- Tal distribuição é obtida por meio do quociente entre duas variáveis com distribuição Qui-Quadrado, dividido pelos respectivos graus de liberdade.

Definição 1 (Distribuição F)

Se X_{11}, \dots, X_{1n} e X_{21}, \dots, X_{2m} denotam duas a.a.'s retiradas de uma mesma população normal, com média μ e variância σ^2 , defina as quantidades, $U = \sum_{i=1}^n \left(\frac{X_{1i} - \bar{X}_1}{\sigma} \right)^2 \sim \chi_{n-1}^2$ e $V = \sum_{i=1}^m \left(\frac{X_{2i} - \bar{X}_2}{\sigma} \right)^2 \sim \chi_{m-1}^2$.

Então, pelo teorema de Snedecor, segue que,

$$W = \frac{U/(n-1)}{V/(m-1)} \sim F_{(n-1, m-1)}.$$

Distribuição F de Snedecor

- Assim, a fdp da v.a. W com distribuição $F_{(n-1, m-1)}$ de Snedecor é dada por:

$$f(w|n, m) = \frac{\Gamma\left(\frac{n+m-2}{2}\right) \left(\frac{n-1}{m-1}\right)^{\frac{n-1}{2}} w^{\frac{n-1}{2}}}{\Gamma\left(\frac{n}{2}\right) \Gamma\left(\frac{m}{2}\right) \left[\left(\frac{n-1}{m-1}\right) w + 1\right]^{(n+m-2)/2}}, \quad 0 < w < \infty.$$

- Segue da definição 9 temos igualmente que,

$$W = \frac{U/(n-1)}{V/(m-1)} = \frac{\frac{(n-1)S_1^2/\sigma^2}{n-1}}{\frac{(m-1)S_2^2/\sigma^2}{m-1}} = \frac{S_1^2}{S_2^2} \sim F_{(n-1, m-1)}.$$

Distribuição F de Snedecor

- A média e variância de uma v.a. com distribuição $F_{(n-1, m-1)}$ são dadas por (os detalhes não serão apresentados aqui):

$$\mathbb{E}(W) = \frac{m-1}{m-3}, \text{ com } m > 3$$

$$\text{Var}(W) = \frac{2(m-1)^2(n+m-4)}{(n-1)(m-3)^2(m-5)}, \text{ para todo } n > 1, m > 5.$$

- A distribuição F é assimétrica positiva, onde seu aspecto gráfico depende dos valores de n e m .
- Se a v.a. $W \sim F_{(n-1, m-1)}$ então, $\frac{1}{W} \sim F_{(m-1, n-1)}$.

Distribuição t -Student

- Entre as distribuições de probabilidades apresentadas até o momento, a distribuição t -Student é que está mais próxima da distribuição normal. Ou seja, ela é um caso particular da distribuição normal.

Definição 2

Seja Z uma v.a. com distribuição normal padrão, e U uma v.a. com distribuição χ^2_{n-1} . Então, a v.a.

$$Y = \frac{Z}{\sqrt{\frac{U}{n-1}}} = \frac{\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{U}{n-1}}} \sim t_{(n-1)}. \quad (3)$$

Distribuição t -Student

- A fdp de uma v.a. com distribuição t -Student pode ser derivada usando o método de Jacobiano, ou mesmo com base na fgm (os detalhes não serão apresentados aqui). Assim,

$$f_Y(y|n) = \frac{\Gamma\left(\frac{n-1}{2}\right)}{\Gamma\left(\frac{n}{2}\right) \sqrt{\pi(n-1)}} \left(1 + \frac{y^2}{n-1}\right)^{-n/2},$$

com $n - 1$ denotando o número de graus de liberdade da distribuição t -Student.

- Os principais momentos da distribuição t -Student são:

$$\begin{aligned}\mathbb{E}(Y) &= 0. \\ \text{Var}(Y) &= \frac{n-1}{n-3}, \text{ com } n > 3.\end{aligned}$$

Note que, $\text{Var}(Y) \rightarrow 1$, quando $n \rightarrow \infty$.

Distribuição *t*-Student

Definição 3

Se X_1, \dots, X_n denota uma a.a. proveniente de uma distribuição normal de média μ e variância σ^2 . Ademais, vimos que $U \sim \chi_{n-1}^2$, portanto, usando o fato de que \bar{X}_n e $(n-1)S^2$ são independentes (fato que não será provado aqui), então, segue que:

$$Y = \frac{Z}{\sqrt{\frac{U}{n-1}}} = \frac{(\bar{X}_n - \mu)}{S/\sqrt{n}} \sim t_{n-1}. \quad (4)$$

- Ou seja, nos casos em que a amostra é proveniente de uma população normal, porém, com σ^2 desconhecido a quantidade acima segue uma distribuição *t*-Student com $n-1$ graus de liberdade.

Distribuição t -Student

Algumas Característica da Distribuição t -Student

- a A distribuição t -Student é simétrica em de zero, isto é, $\mathbb{E}(T) = 0$.
- b Valores menores de graus de liberdade levam a distribuição t -Student com caudas mais pesadas e a intervalos de confiança maiores.
- c Quando o número de graus de liberdade aumenta a distribuição t -Student se aproxima da distribuição $\mathcal{N}(0, 1)$.
- d O quadrado de uma v.a. Y com distribuição t de Student com $n - 1$ graus de liberdade tem uma distribuição F de Snedecor com 1 e $n - 1$ graus de liberdade. Isto é, se $Y \sim t_{n-1}$, então, $Y^2 \sim F_{(1, n-1)}$.

Distribuição t -Student




Figura: Formas da distribuição t -Student quando o número de graus de liberdade aumenta.

Distribuição Amostral de $\bar{X}_{1n} - \bar{X}_{2m}$

- Nas aulas anteriores abordamos a distribuição da média amostral obtida de uma única população.
- Em alguns casos, é de suma importância para o pesquisador comparar (ou fazer inferência) com o intuito de obter algumas conclusões sobre os parâmetros de duas ou mais populações.
- Neste tópico vamos derivar as distribuições amostrais da diferença de médias baseadas em a.a.'s provenientes de populações diferentes. Para tal, vamos considerar *três casos principais*.

Distribuição Amostral de $\bar{X}_{1n} - \bar{X}_{2m}$

Caso 1

Assuma que as duas a.a. X_{11}, \dots, X_{1n} e X_{21}, \dots, X_{2n} são provenientes de duas populações normais caracterizadas pelos parâmetros de média μ_1 e μ_2 , e de variância σ_1^2 e σ_2^2 , isto é, $X_{1i} \sim \mathcal{N}(\mu_1, \sigma_1^2)$ e $X_{2i} \sim \mathcal{N}(\mu_2, \sigma_2^2)$, respectivamente.

- Seja \bar{X}_{1n} e \bar{X}_{2m} as médias obtidas por meio das duas a.a.'s selecionadas nas duas populações. Supondo que as variâncias populacionais são conhecidas, mas com $\sigma_1^2 \neq \sigma_2^2$, segue que,
$$\bar{X}_{1n} - \bar{X}_{2m} \sim \mathcal{N}\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}\right).$$

Distribuição Amostral de $\bar{X}_{1n} - \bar{X}_{2m}$

- Ou seja, pelo teorema de aditividade da distribuição normal, segue que,

$$\frac{(\bar{X}_{1n} - \bar{X}_{2m}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim \mathcal{N}(0, 1),$$

com n e m denotando os tamanhos amostrais, que podem ser iguais ou diferentes.

- Observe que, se as a.a.'s forem provenientes de duas populações quaisquer, com $n, m \geq 30$, o TCL pode ser aplicado para obter a normalidade assintótica da quantidade acima.

Distribuição Amostral de $\bar{X}_{1n} - \bar{X}_{2m}$

Caso 2

Neste caso, vamos assumir que as a.a.'s X_{11}, \dots, X_{1n} e X_{21}, \dots, X_{2n} são provenientes de duas populações normais, $X_{1i} \sim \mathcal{N}(\mu_1, \sigma_1^2)$ e $X_{2i} \sim \mathcal{N}(\mu_2, \sigma_2^2)$ com $\sigma_1^2 \neq \sigma_2^2$, sendo ambas desconhecidas. Neste caso, vamos usar os estimadores não-viesados para σ_1^2 e σ_2^2 , respectivamente.

Assim,

$$\frac{(\bar{X}_{1n} - \bar{X}_{2m}) - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}} \sim t_{(v)},$$

com $v = \frac{\left(\frac{s_1^2}{n} + \frac{s_2^2}{m}\right)^2}{\left(\frac{s_1^2}{n}\right)^2 / (n-1) + \left(\frac{s_2^2}{m}\right)^2 / (m-1)}$, denotando o número de graus de liberdade.

- Para $n, m \geq 30$, a quantidade acima segue uma distribuição normal padrão.

Distribuição Amostral de $\bar{X}_{1n} - \bar{X}_{2m}$

Caso 3

Supondo agora que as variâncias populacionais σ_1^2 e σ_2^2 são ambas desconhecidas, mas que as duas populações apresentam a mesma variabilidade, isto é, $\sigma_1^2 = \sigma_2^2$, segue imediatamente que, se $n, m < 30$ então,

$$\frac{(\bar{X}_{1n} - \bar{X}_{2m}) - (\mu_1 - \mu_2)}{\sqrt{S_p^2 \left(\frac{1}{n} + \frac{1}{m} \right)}} \sim t_{(n+m-2)},$$

onde S_p^2 denota a variância ponderada, cuja sua expressão é dada por:

$$S_p^2 = \frac{(n-1) S_1^2 + (m-1) S_2^2}{n+m-2}.$$

Distribuição Amostral de $\hat{p}_{1n} - \hat{p}_{2m}$

- Considere duas populações Bernoulli, caracterizadas pelos parâmetros P_1 e P_2 , que denotam as verdadeiras proporções de ocorrência do sucessos nas duas populações.
- Em muitas situações práticas, é de suma importância fazer inferência em duas ou mais populações independentes. Como por exemplo:
 - Podemos estar interessados em comparar a proporção de consumidores interessados em um novo produto na área rural, com a da área urbana.
 - Podemos estar interessados em inferir as proporções de respostas favoráveis a uma campanha publicitária feita em dois seminários diferentes, entre outros exemplos.
- Nos exemplos supracitados, pretende-se concluir algo sobre a quantidade $p_1 - p_2$ que se desconhece.

Distribuição Amostral de $\hat{p}_{1n} - \hat{p}_{2m}$

Definição 4

Considere X_{11}, \dots, X_{1n} e X_{21}, \dots, X_{2m} duas a.a. provenientes de duas populações de Bernoulli, isto é, $\text{Ber}(p_1)$ e $\text{Ber}(p_2)$, respectivamente. Se $S_n = \sum_{i=1}^n X_{1i}$ e $S_m = \sum_{i=1}^m X_{2i}$ denotam o número de sucessos em experimentos de Bernoulli independentes, as proporções amostrais são dadas por:

$$\hat{p}_{1n} = \frac{S_n}{n} \text{ e } \hat{p}_{2m} = \frac{S_m}{m}$$

Com base nos resultados da Definição 12, e do TCL, segue imediatamente que, $\hat{p}_{1n} \sim \mathcal{N}(p_1, p_1(1-p_1)/n)$, e $\hat{p}_{2m} \sim \mathcal{N}(p_2, p_2(1-p_2)/m)$, quando $n, m \rightarrow \infty$.

Distribuição Amostral de $\hat{p}_{1n} - \hat{p}_{2m}$

- A consequência direta do resultado anterior, é:

$$\hat{p}_{1n} - \hat{p}_{2m} \sim \mathcal{N} \left(p_1 - p_2, \frac{p_1(1-p_1)}{n} + \frac{p_2(1-p_2)}{m} \right), \quad n, m \rightarrow \infty.$$

- De igual forma, a normalidade acima implica que,

$$\frac{(\hat{p}_{1n} - \hat{p}_{2m}) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n} + \frac{p_2(1-p_2)}{m}}} \sim \mathcal{N}(0, 1) \text{ quando } n, m \rightarrow \infty. \quad (5)$$

- Assim, o resultado em (5) estabelece a distribuição amostrar para a diferença de proporções amostrais.

Distribuições Amostrais dos Extremos

- Nesta parte da disciplina vamos apresentar a noção (ou conceito) de estatísticas de ordem. Como por exemplo, a menor e maior observação de um conjunto de dados, respectivamente.
- O processo que consiste em obter as estatísticas extremas é muito fácil. Porém, para obter a distribuição amostral associada a tais estatísticas exige um trabalho considerável.
- Portanto, a obtenção das distribuições associadas às estatísticas extremas é por vezes importante na literatura estatística.

Definição 5

Seja X_1, \dots, X_n uma a.a. de X , extraída de uma população que é caracterizada pela fdp $f_X(x)$.

Distribuições Amostrais dos Extremos

- Se X_1, \dots, X_n denota a a.a. da definição anterior, considere $X_{(1)} < X_{(2)} < \dots < X_{(n)}$ os valores ordenados da a.a. (ou estatísticas de ordem). Tal que, $X_{(j)}$ para todo $1 \leq j \leq n$ a j -ésima estatística de ordem.
- Desta forma, $X_{(1)} = \min \{X_1, \dots, X_n\}$ denota a menor observação, e $X_{(n)} = \max \{X_1, \dots, X_n\}$ a maior observação da a.a.
- A distribuição amostral para qualquer estatística de ordem $X_{(j)}$ pode ser obtida. No entanto, nessa disciplina nos restringiremos apenas nas distribuições das estatísticas extremas, $X_{(1)}$ e $X_{(n)}$.

Distribuições Amostrais dos Extremos

Distribuição do Máximo: antes de procedemos com derivação da fda de uma estatística de ordem, considere $F(x)$, tal que,

$$F_X(x) = P(X \leq x) = \int_0^x f_X(y) dy$$

- Assim, nosso interesse reside em obter a fda e fdp associada às estatísticas extremas. Assim, a distribuição do máximo é dada por:

$$\begin{aligned} F_{X_{(n)}}(x) &= P(X_{(n)} \leq x) = P(\max\{X_1, \dots, X_n\} \leq x) \\ &= P(X_1 \leq x, \dots, X_n \leq x) = [P(X_1 \leq x)]^n \\ &= [F_X(x)]^n. \end{aligned}$$

- Consequentemente, a fdp do máximo é dada por:

$$f_{X_{(n)}}(x) = \frac{d}{dx} F_{X_{(n)}}(x) = n f_X(x) [F_X(x)]^{n-1}.$$

Distribuições Amostrais dos Extremos

Distribuição do Mínimo: usando a mesma abordagem apresentada anteriormente, podemos derivar facilmente a fda e fdp do mínimo. Para tal,

$$F_{X_{(1)}}(x) = P(X_{(1)} \leq x) = 1 - P(X_{(1)} > x) \quad (6)$$

Observe agora que,

$$\begin{aligned} P(X_{(1)} > x) &= P(\min\{X_1, \dots, X_n\} > x) \\ &= P(X_1 > x, \dots, X_n > x) = [P(X_1 > x)]^n \\ &= [1 - F_X(x)]^n. \end{aligned}$$

Distribuições Amostrais dos Extremos

- Com base na expressão em (6), obtemos a fda de $X_{(1)}$ representada por:

$$F_{X_{(1)}}(x) = P(X_{(1)} \leq x) = 1 - P(X_{(1)} > x) = 1 - [1 - F_X(x)]^n$$

- Por fim, a fdp do mínimo, $X_{(1)}$ tem o seguinte formato:

$$f_{X_{(1)}}(x) = \frac{d}{dx} F_{X_{(1)}}(x) = n f_X(x) [1 - F_X(x)]^{n-1}.$$

- É importante salientar que, uma expressão geral para computar a distribuição amostral da j -ésima estatística de ordem é estabelecida pelo teorema abaixo.

Distribuições Amostrais dos Extremos

Teorema 6

Sejam $X_{(1)} < \dots < X_{(n)}$ estatísticas de ordem obtidas por meio de uma a.a. extraída de uma população caracterizada pela fdp $f_X(x)$ e fda $F_X(x)$. Então, a fdp da j -ésima estatística de ordem, $X_{(j)}$ é dada por:

$$f_{X_{(j)}}(x) = \frac{n!}{(j-1)!(n-j)!} f_X(x) \{F_X(x)\}^{j-1} \{1 - F_X(x)\}^{n-j},$$

com $1 \leq j \leq n$.

Distribuições Amostrais dos Extremos

Exemplo 10: Seja X uma v.a. extraída de uma população com distribuição uniforme, isto é, $X \sim \mathcal{U}(10; 20)$. Assuma que X_1, X_2, X_3, X_4, X_5 denote uma a.a. selecionada dessa mesma população. Assim, pede-se para:

- a) Calcular a probabilidade de que o mínimo da amostra seja maior que 12.
- b) Calcular a probabilidade de que o máximo da amostra seja menor que 15.